Messen und Bewerten von Kompetenzen
Leistungsmessung 1

Sitzung 1 ..... **Fehler! Textmarke nicht definiert.**
Begriffsklärung 2
1. Funktionen von Notengebung 3
2. Gütekriterien der Leistungsbewertung 5
3. Leistungsarten und Erhebungsanlässe, Transparenz 8
4. Bezugsnormen in der Schule 10
5. Systematische Beurteilungsfehler 13

Lutz Eisele, mit Materialien von Elke Stenger

Begriffsklärung

(aus Brüning, Ludger; Saum, Tobias: Leistungsbeurteilung im Kooperativen Lernen)

Im Zusammenhang mit Leistungsbewertung werden folgende Begriffe (meist) so verwendet:



Abbildung 2: Begriffe der Leistungsbewertung

Leistungsmessung

Hier geht es lediglich darum, Leistungen zu erheben oder zu beobachten. Ob diese Leistungen einen individuellen Fortschritt darstellen, mit Anstrengungen verbunden sind, in welchem Verhältnis sie zur Lerngruppe oder einer Sachnorm stehen, wird bei der Leistungsmessung noch nicht gesagt.

Leistungsbeurteilung

Bei der Leistungsbeurteilung wird eine Aussage zur Qualität der erbrachten Leistung gemacht. Im Alltag geschieht dies immer, wenn den Schülerinnen und Schülern eine Rückmeldung zur ihren Beiträgen im Unterricht gegeben wird. In komplexeren Beurteilungssituationen wird die Leistung genauer beschrieben und auch in Beziehung zu Normen und Erwartungen gesetzt. Ein umfassender Kommentar unter einer Klassenarbeit bzw. Klausur oder das Ausfüllen eines Kriterienrasters gehört zum Beispiel in den Bereich der Leistungsbeurteilung. Schriftliche Beschreibungen der Leistungsentwicklung zum Beispiel in Berichtszeugnissen gehören ebenfalls in den Bereich der Leistungsbeurteilung.
Die Leistungsbeurteilung ist die Grundlage für Beratungsgespräche mit den Schülerinnen und Schülern oder auch mit ihren Eltern. Gleichzeitig erlaubt erst die differenzierte Leistungsbeurteilung eine genaue Diagnose des Leistungsvermögens und stellt daher den Ausgangspunkt für eine individuelle Förderung der Lernenden dar.

Notengebung

Die meisten Lehrpersonen sind in ihren Schulen aufgefordert, die von den Schülerinnen und Schülern erbrachten Leistungen in Form einer Ziffernnote auszudrücken. Ist dies der Fall, sprechen wir von Notengebung. Nach unserer Definition muss die eigentliche Leistungsbeurteilung nicht zwingend mit der Notengebung verbunden sein, gleichwohl kann letztere nur au Basis der Messung und Beurteilung erfolgen.

Leistungsbewertung

Den gesamten Prozess nennen wir Leistungsbewertung. Sie beginnt mit der Beobachtung und führt dann zur Leistungsbeurteilung. Im Einzelfall folgt dann die Notengebung.
Alle vier Begriffe stehen in einem engen Beziehungsgefüge: Ohne Leistungsmessung oder -beobachtung kann keine Beurteilung erfolgen, und erst die Beurteilung erbrachter Leistungen erlaubt eine begründete Notengebung.

1. Funktionen von Notengebung

Grundsätze der Notenbildung

(Aus: Schulverwaltung BW Nr. 10/2002, Autor: Johannes Lambert)

Grundlage der Leistungsmessung ist im Wesentlichen die Verordnung zur Notenbildung. Ihr liegen einige wenige Prinzipien zugrunde, die nicht alle ausdrücklich formuliert sind, sondern zum Teil zwischen den Zeilen zu lesen sind, die aber andererseits erst den Schlüssel zum Verständnis vieler Einzelregelungen bilden. Im Folgenden soll an diese Prinzipien erinnert werden [...].

Ausgangslage

Ausgangspunkt ist die Überlegung, dass die Notengebung an sich kein essentieller Bestandteil des Unterrichts ist. Die Leistungsmessung durch Noten wurde − beginnend im 18. Jahrhundert − nicht aus pädagogischen, sondern aus gesamtgesellschaftlichen Gründen eingeführt: Nach dem Prinzip der Chancengleichheit sollen über den Zugang zu begehrten Positionen nicht Herkunft oder Beziehungen oder die finanzielle Ausstattung, sondern ausschließlich die Tüchtigkeit des Einzelnen entscheiden. Dann ist aber eine nach allgemeinen Anforderungen definierte Leistungsmessung erforderlich − eine Aufgabe, mit der nach den Traditionen in Deutschland vorwiegend die Schulen beauftragt sind.
Mit der Notengebung erfüllt die Schule also keine originär pädagogische, sondern eine gesamtgesellschaftliche Aufgabe. Dass aus rein pädagogischen Gründen eine Notenbildung nicht notwendig ist, zeigt heute noch die Heranbildung der Berufsmusiker für professionelle Chöre, Orchester oder Bands: Die Schüler bilden ihre Stimme oder lernen ihr Instrument im Privatunterricht ohne formalisierte Leistungsmessung und unterziehen sich anschließend einer Aufnahmeprüfung in den Musikhochschulen.
Die Noten können sicherlich in vielfältiger Weise pädagogisch nutzbar gemacht werden. Sie können in dem pädagogisch-didaktischen Prozess des Unterrichts aber auch störende Auswirkungen haben. Sie führen bisweilen zu menschlich harten Entscheidungen, als Grundlage individueller Berechtigungen bleiben sie auf den einzelnen Schüler bezogen und können so der Erziehung zur Teamfähigkeit im Wege stehen, sie setzen ein landesweit definiertes Anforderungsprofil voraus, was die pädagogische Freiheit von Schule und Fachlehrer einschränkt, und die Einzelregelungen der Leistungsmessung können auch den Unterricht in pädagogisch unguter Weise determinieren.
Es macht keinen Sinn, die unbestreitbare Möglichkeit solcher Nachteile zu leugnen. Genauso wenig würde es aber einen Sinn geben, deswegen eine Schule ohne Noten zu verlangen,

denn dies würde die angesprochenen Nachteile eher verschärfen. Unsere moderne Industriegesellschaft wird nämlich auf das Prinzip der Chancengleichheit nicht verzichten, wird also auf alle Fälle den Zugang zu begehrten Positionen von der Tüchtigkeit der Bewerber abhängig machen. Wenn sich die Schule der dafür notwendigen Aufgabe einer Leistungsmessung verweigert, wird es zu den vielfältigen weiterführenden Bildungs- und Ausbildungsgängen Aufnahmeprüfungen geben.
Die damit verbundenen menschlichen Härten würden aber größer sein als nach dem herkömmlichen System. Zum einen sind punktuelle Aufnahmeprüfungen weniger gerecht, da der Entscheidung lediglich die Leistung in der Prüfung, nicht mehr die lange Beobachtung durch die Schule zugrunde liegt. Zudem wären ablehnende, das heiß begehrte Bildungs- oder Ausbildungsangebote verweigernde Entscheidungen bei einem Aufnahmesystem über Eingangsprüfungen für die Betroffenen psychisch härter, da sie nicht mehr über das in langer Unterrichtszeit aufgebaute menschliche Verhältnis des Lehrers zum Schüler vermittelt, sondern durch eine anonyme Prüfungsbehörde zugestellt werden.
Auch für den pädagogischen Freiraum von Schule und Lehrer wäre nichts gewonnen. Denn natürlich würden Schüler und Eltern und damit notgedrungen auch die Lehrer auf die Anforderungen der jeweiligen Aufnahmeprüfungen „schielen“, denn allein auf das dort Verlangte würde es ankommen. Die Bestimmungsmacht über die Schulen würde also zu einem guten Teil auf diejenigen übertragen, die die Anforderungen für die Aufnahmeprüfungen formulieren.
Es macht auch keinen Sinn, von den Maßstäben einer korrekten Leistungsmessung abzuweichen, um pädagogische Nachteile der Notengebung zu vermeiden. Als Beispiel sei an die Diskussion um die Bewertung von Gruppenarbeiten erinnert. Hier muss es die Kunst des Lehrers bleiben, den individuellen Beitrag des einzelnen Schülers zur Gesamtleistung der Gruppe zu eruieren. Andernfalls würde die Notengebung schlicht falsch. Könnte sich die Gesellschaft aber nicht mehr auf die Notengebung der Schule verlassen, so würde dies die Tendenz zu zeugnisunabhängigen Aufnahmeprüfungen verstärken − mit den oben beschriebenen Nachteilen.
Diese Überlegungen sind der Ausgangspunkt unseres Systems der Notenbildung: Dieses System bleibt den Prinzipien einer korrekten Notengebung verpflichtet, enthält aber zugleich Vorkehrungen, um die damit verbundenen Nachteile zu mildern.

Welche Funktionen haben Prüfungen, Zeugnisse und Zensuren?

(Aus: http://www.didaktik.uni-jena.de/did_05/funktion.htm 17.04.08)

1. Selektions- und Zuteilungsfunktion
   Mit der Zensierung werden Berechtigungen für den weiteren sozialen Aufstieg vergeben oder verwehrt.
2. Sozialisation
   Durch Prüfungen, Noten und Zeugnisse wird die nachwachsende Generation in die Leistungsorientierung unserer Gesellschaft eingeübt.
3. Kontrolle
   Prüfungen, Zeugnisse und Noten dienen auch der Kontrolle der Lehrer und der Lehrpläne sowie ganzer Schulen, Schularten und Schulsysteme.
   Im Allgemeinen gelten gute Noten als Indiz für erfolgreiches Lehren und Lernen.
   Zugleich wird ein gewisser Anteil an schlechten Noten als Ausweis dafür genommen, dass etwas verlangt wird.
4. Prognose
   Die meisten „Abnehmer“ von Zeugnissen und Noten, auch die betroffenen Schüler selbst, interpretieren diese prognostisch, d.h. sie leiten Erwartungen hinsichtlich des weiteren Lernfortschritts und der künftigen Leistung daraus ab.

5. Information und Rückmeldung
   Prüfungsergebnisse, Noten und Zeugnisse informieren Schüler, Eltern und Lehrer über den erreichten Lernstand und die gemachten Lernfortschritte.
   Lehrer benötigen in regelmäßigen Abständen eine Diagnose des Lernstandes der Schüler als Grundlage für die Gestaltung des weiteren Unterrichts. Erst in Kenntnis der Lernvoraussetzungen, des Leistungsstandes und der zutage getretenen Defizite können Lehr- und Lernprozesse sinnvoll geplant werden.
6. (Selbst-) Disziplinierung bzw. Motivation
   Die Rückmeldungen, welche Schüler über ihre Leistungen und vor allem Ihre Lernerfolge erhalten, haben oft auch einen (selbst-) disziplinierenden bzw. motivierenden Effekt: Sie können z.B. eine realistischere Selbsteinschätzung und vermehrte Anstrengungsbereitschaft bewirken. Prüfungen und Noten haben Rückwirkungen auf die Leistungserziehung der Schüler. Sie sind Teil einer Erziehung zum eigenverantwortlichen Handeln. Solche Lernerziehung ist nötig, weil die Schüler eines Tages ihre Lernprozesse ohne fremde Hilfe organisieren können müssen.

2. Gütekriterien der Leistungsbewertung

(Vor allem orientiert an:
http://bebis.cidsnet.de/weiterbildung/sps/allgemein/bausteine/beurteilung/....htm, 17.04.08)

Die Kriterien, nach denen die Güte eines Tests beurteilt wird, werden eingeteilt in Haupt- und Nebenkriterien. Die Hauptkriterien eines Tests betreffen:

Objektivität

Eine Messung gilt dann als objektiv, wenn verschiedene Untersucher desselben Merkmals unabhängig voneinander zu demselben Messergebnis kommen. Anders gesagt: eine Messung ist dann objektiv, wenn subjektive Einflüsse der Untersucher möglichst ausgeschaltet werden können.

In der schulischen Leistungsbeurteilung müssen mehrere Arbeitsebenen unterschieden werden:
- Durchführung der Leistungsüberprüfung - deren Verfahren,
- Auswertung der erbrachten Leistungen - deren Ermittlung,
- Interpretation der ermittelten Ergebnisse - deren Auswertung.

In der Schulpädagogik bestehen die entscheidenden Schwierigkeiten auf der Ebene der Auswertung und der Interpretation; sie werden noch verstärkt durch die Neigung vieler Lehrer, Feststellung bzw. Messung der Schülerleistungen nicht konsequent genug von deren Wertung bzw. Interpretation zu trennen.

Die Bewertung einer Schülerleistung ist also dann „objektiv“ (da echte Objektivität dabei realistisch betrachtet nicht möglich ist, spricht man auch von „Intersubjektivität“ oder von „kontrollierter Subjektivität“, also zwischen unterschiedlichen Subjekten – nahezu - gleich), wenn verschiedene Lehrpersonen bei der Beurteilung einer Schülerleistung zum gleichen Ergebnis kommen. Dies bezieht sich sowohl auf die Aufgabenstellung (wie schwer war die Klausur?), wie die Korrektur (anhand welcher Kriterien vergebe ich Punkte?) und die Bewertung (was lasse ich noch als richtig gelten?).

Validität – Gültigkeit

Der Begriff und das Kriterium „Gültigkeit" beziehen sich auf den Gegenstand einer Messung oder Untersuchung. Ein Untersuchungsverfahren ist dann gültig, wenn es das Merkmal misst, das es messen soll - und nichts Anderes.

Untersuchungsverfahren sind nie allgemein, sondern immer nur spezifisch gültig. Für die Praxis des Unterrichts ist die Inhaltsgültigkeit (curriculare Gültigkeit) besonders bedeutsam. Eine Lernzielkontrolle soll sich möglichst genau auf den erteilten Unterricht und dessen Ergebnisse beziehen. Dies beinhaltet auch die beiden Grundsätze:

- Proportionale Abbildung (die Prüfung spiegelt den Umfang und das Anspruchsniveau, mit dem das Thema im Unterricht behandelt wurde, im Unterricht wider) und
- Variabilität (unterschiedliche Aufgabenarten für unterschiedliche Schüler“typen“)

Die Gültigkeit kommt aber auch dadurch zum Ausdruck, dass ich nicht (absichtlich oder aus Unachtsamkeit) etwas messe, was ich an der Stelle gar nicht messen will: Wenn die Klassenarbeit so viele Aufgaben umfasst, dass kaum ein Schüler rechtzeitig fertig wird, messe ich weniger die inhaltliche Qualität als das Kriterium „schnelles Arbeiten“ oder die Stressresistenz.

Reliabilität – Zuverlässigkeit

Der Begriff und das Kriterium „Zuverlässigkeit" beziehen sich auf das Verfahren einer Messung oder Untersuchung. Ein Untersuchungsverfahren ist dann zuverlässig, wenn es das Merkmal, das es messen soll, genau bzw. exakt misst. Eine Wiederholung der Messung müsste also zu gleichen Ergebnissen führen.

Die ermittelte Messgenauigkeit von Testverfahren bezieht sich jeweils immer auf das untersuchte Kollektiv und nicht auf ein einzelnes Individuum, wodurch auch durch die Reliabilität eines Tests die Messgenauigkeit im Hinblick auf die Ermittlung individueller Gegebenheiten nicht völlig abgesichert ist.

Eine Beurteilung ist also dann reliabel, wenn sich das Ergebnis bei wiederholten Beurteilungen nicht ändert. Da eine Klassenarbeit natürlich nicht wie unter Laborbedingungen einfach ein zweites Mal geschrieben werden kann, besteht die Aufgabe darin, darauf zu achten, dass das gleiche Ergebnis herauskäme, falls die Arbeit ein zweites Mal geschrieben werden könnte. De facto bedeutet dies, z.B. möglichst den Zufall zu reduzieren, dass ein bestimmtes Ergebnis herauskommt. Dies erreicht man beispielsweise, indem man behandelten Unterrichtsstoff möglichst breit in der Arbeit abbildet und nicht nur zwei zufällige von fünf Themenbereichen herausgreift. Oder indem man ein Beurteilungsmerkmal möglichst häufig prüft. Zum Beispiel: wenn ich in einer Deutschklausur die richtige Verwendung von „dass“ und „das“ testen möchte, erreiche ich zuverlässigere Ergebnisse, wenn ich dies an 20 Sätzen erprobe, als wenn ich dazu nur zwei Sätze heranziehe. Ein IQ-Test sollte z.B. bei einer Person ab einem bestimmten Alter, immer den gleichen Werte ergeben, wenn man davon ausgeht, dass die Intelligenz einer Person stabil ist.

Zielbeziehungen

Wie man an dem obigen Beispiel rasch zeigen kann, stehen die drei Ziele tendenziell in Konfliktbeziehung zueinander. So kann die Validität leicht unter der Reliabilität leiden, wenn ich z. B. ein Thema so breit abprüfe, dass die Schüler dadurch in Zeitnot und Stress geraten.

Auch das Ziel Objektivität kann dem Kriterium Validität entgegenstehen. Die größte Auswertungsobjektivität erziele ich sicherlich mit Multiple-Choice- oder Lückenaufgaben, da die Person des Auswerters hier quasi keine Rolle spielt. Allerdings ist dann zu fragen, ob ich dann wirklich noch valide das messe, was ich messen will. Komplexere Schülerleistungen (Berechnungen durchführen, begründete Urteile fällen etc.) sind auf diesem Wege nur schwer überprüfbar. Gerade Multiple-Choice-Aufgaben messen evtl. nicht wirklich valide (Chance, das Richtige zu raten) und reliabel (komplexe Antwortformulierungen können dazu führen, dass Schüler bei einer Wiederholung die Lösungsmöglichkeiten anders verstehen und dadurch zu einer anderen Lösung kommen könnten).

In der Praxis wird es also nicht möglich sein, allen Zielen vollständig zu genügen. Die hohe Kunst der Leistungsbewertung besteht also hier − wie so oft − in einer „gesunden Mischung".

Für den Fall mündlicher Prüfungen steigt aber die Wahrscheinlichkeit des Einhaltens aller Kriterien tendenziell damit, dass ich vorher genau festlege, was ich fragen werde. Dies wirkt sich positiv auf die Objektivität (klare Fragestellung auch für andere), Validität (ich habe mir genau überlegt, welche Fragen ich stelle, so dass nicht während der Prüfung Sachen frage, die mir gerade einfallen und evtl. den Stoff gar nicht wirklich prüfe) und Reliabilität (da ich bei einer weiteren Prüfung genau dieselben Fragen stellen würde).

Zusatz

Objektivität

- Ist ein Maß dafür, inwieweit die Ergebnisse einer Testung unabhängig von der Person des Testleiters und des Auswerters sind

Reliabilität

- Ist ein Maß für die Genauigkeit, mit der ein Test ein zu messendes Merkmal erfasst
- Reliabilitäten können auf mehrere Weisen geschätzt werden: Durch Testwiederholung (Retest-Reliabilität), Vorsicht vor Erinnerungs- und Übungseffekten oder durch Paralleltests

Validität

- Gibt an, inwieweit ein Test das intendierte Merkmal tatsächlich erfasst (Gültigkeit).
- Nach klassischer Testtheorie kann ein Test, der nicht reliabel ist, auch nicht valide sein.
- Allerdings ist es möglich, dass ein reliabler Test nicht valide ist. Der Test misst dann zwar genau, aber nicht das, was man erfassen möchte.

Einschätzungen der Reliabilität und der Validität sind zwei unabhängige Prozeduren.

Diskussionsfrage zur Verdeutlichung: Wann ist ein Intelligenztest objektiv, valide und reliabel?

3. Leistungsarten und Erhebungsanlässe, Transparenz

Ausgewählte Leistungsarten

Die Leistungsbeurteilung soll ein möglichst umfassendes Bild des Leistungsvermögens jedes Schülers abgeben. Gemäß § 7(1) der Notenbildungsverordnung (kurz NVO) sind daher alle vom Schüler im Unterricht erbrachten Leistungen zu bewerten. Es ist deshalb z.B. unzulässig, bei jedem Schüler die schlechteste Arbeit wegfallen zu lassen oder eine Leistungsart, z.B. mündliche Leistungen, überhaupt nicht zu bewerten.

Schriftliche Leistungen sind Klassenarbeiten und schriftliche Wiederholungsarbeiten, aber auch Vokabeltests oder Hausaufgaben.

Mündliche Leistungen sind in jedem Fall zu bewerten, da die unterschiedliche Befähigung jedes Schülers zur Geltung kommen kann. Manche Schüler sind in ihren mündlichen Leistungen wesentlich besser als in ihren schriftlichen, daher muss auch diesen Schülern die Chance gegeben werden, ihre Stärke mit in die Note einfließen zu lassen.
Die Bewertung von mündlichen Leistungen gestaltet sich oftmals schwierig. Es ist z.B. darauf zu achten, dass nicht schriftliche Leistungen wie Hausaufgaben oder Vokabeltests für die Leistungsmessung herangezogen werden. Es ist allerdings zulässig, dass Schüler beim mündlichen Abhören etwas an die Tafel schreiben oder zeichnen.

Beispiele für Lernbeobachtungen und Leistungsrückmeldungen

Aus: http://www.didaktik.uni-jena.de/did_05/beispiele.htm 17.04.08

Im Folgenden werden exemplarisch drei Beispiele zur Erfassung und Beurteilung schulischer Leistungen vorgestellt und kurz erörtert. Die Beispiele lassen eine Steigerung der Komplexität im Hinblick auf die Einbeziehung der Schülerinnen in den Beurteilungsvorgang erkennen:

- Der Lehrerbeobachtungsbogen objektiviert die Lehrereinschätzungen durch die Operationalisierung einzelner Lernzielstufen bzw. -dimensionen und bezieht fachliche und überfachliche Beobachtungsdimensionen ein.
- Der korrespondierende Schülereinschätzungsbogen übergibt die Beobachtungskriterien an die Betroffenen und eröffnet ihnen die Möglichkeit, in einer metakommunikativen Situation die Beobachtungen und Einschätzungen des Lehrers nachzuvollziehen und ggf. auf sie einzuwirken. Die Beobachtungs- und Beurteilungskriterien werden auf diese Weise "öffentlich", können sozial kontrolliert und kommunikativ validiert werden. Z.B. Ich-Kann-Listen.
- Die Beurteilungsmatrix geht in der Einbeziehung von Schülerinnen und Schülern zwei Schritte weiter:
  (a) Die Punktebewertung gibt einen Beurteilungsmaßstab vor, der die mögliche Bewertung weitgehend eindeutig macht.
  (b) Da die Beurteilungsmatrix formal jeder mündlichen Referatsleistung zugrunde gelegt wird, ist sie den Schülerinnen und Schülern bekannt. Diese können somit ihre möglichen Leistungen abschätzen und ihre Referate strategisch darauf einstellen.

Weitere Instrumente: Lerntagebücher, Fragebögen (z.B. zur Abfrage des Vorwissens), Portfolios, mündliche Präsentationen, schriftliche Ausarbeitungen, Projekte

Erhebungsanlässe

Diagnostische Beurteilung (= Pädagogische Diagnostik):

Zu Beginn eines Lernprozesses/-einheit, um den Lernstand (Wissen, Kompetenzen, Interessen, Einstellungen) der Lernenden festzustellen.
Eigenschaften: beurteilungsfrei und ggf. anonym. Bsp.: „Ich-kann-Listen“, Eingangstests
Wirkung: realistische Einschätzung der Ausgangslage als Basis für die Planung der nächsten Lernschritte

Formative Beurteilung (= Formative Evaluation, Lernförderliches Feedback):

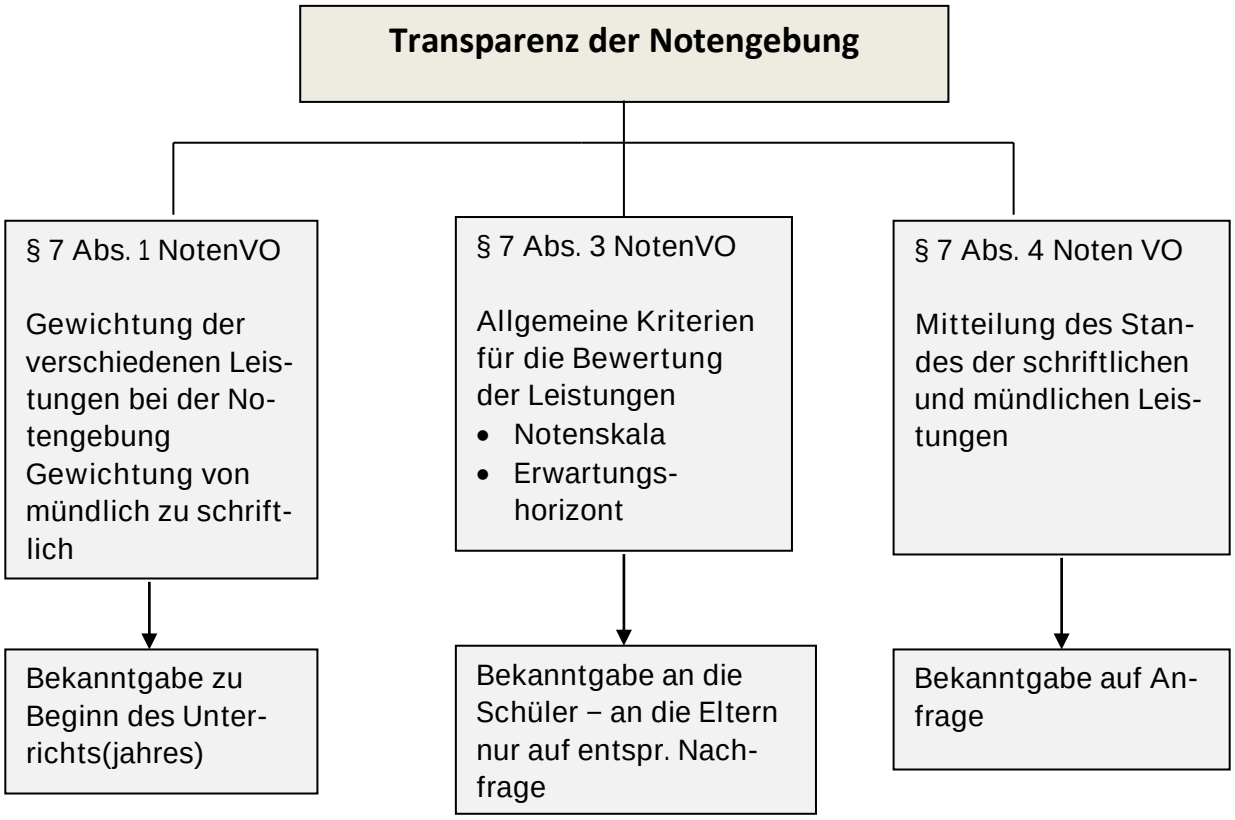
Während des Lernprozesses durchgeführte Bewertung des Lernfortschrittes im Hinblick auf die Zielerreichung. Evtl. Analyse und Beurteilung des Entstehungsprozesses von Handlungsprodukten.
Eigenschaften: meist wertend aber nicht benotet, z.B. „das … ist dir schon gut gelungen, jetzt könntest du ….“
Wirkung: Unterstützung des Lernprozesses der Schüler, Rückmeldung an die Lehrperson zur Planung er nächsten Lernschritte

Summative Beurteilung:

Bewertung des Lernergebnisses am Ende einer Lerneinheit im Hinblick auf die Zielerreichung, z.B. Klassenarbeit.
Eigenschaften: meist benotet, erfüllt weitestgehend die Gütekriterien (Wirkung: siehe Expertenthema „Funktion von Noten“)

Transparenz der Notengebung

Für alle Beurteilungen der Schüler ist die Transparenz der Notengebung grundlegend.



Quelle: Reip, Stefan/ Gayer, Bernhard: Schul- und Beamtenrecht für die Lehramtsausbildung in Baden-Württemberg, Haan-Gruiten 1999, S. 111

Ergänzung: Formative Evaluation

Formative Evaluation hat eine große Wirkung auf den Lernerfolg.
Begriffsklärung: Laut Hattie (2012) und Black & Wiliam (2001) bezieht sich Formative Evaluation auf jegliche Aktivität die dazu benutzt wird, den Lernstand und Lernfortschritt von Schülerinnen und Schülern während des Lernprozesses zu bestimmen.
Die Summative Evaluation dient hingegen dazu, nach der Durchführung des Lernens das Ergebnis zu evaluieren. In einem (englischsprachigen) Video* können Sie mehr über den Unterschied sowie die Vor-und Nachteile von formativer und summativer Evaluation erfahren.

Hinweise für die Unterrichtspraxis
Geben Sie Ihren Schülerinnen und Schülern beschreibendes, lernrelevantes Feedback: Was ist das Ziel? Wo stehst du gerade? Was musst du noch tun, um die Lücke zu füllen?
Verbringen Sie mindestens genauso viel Zeit mit formativer (lernprozess-begleitender) Evaluation wie mit summativer Evaluation (Ergebniskontrolle).

https://www.visible-learning.org/wp-content/files/Glossar-fuer-Begriffe-aus-der-Hattie-Studie-Visible-Learning-Lernen-sichtbar-machen.pdf (08.05.2018, S. 5)
Weblinks
*) Video http://www.youtube.com/watch?v=rJxFXjfB_B4

4. Bezugsnormen in der Schule

(Nach: http://bebis.cidsnet.de/weiterbildung/sps/allgemein/bausteine/beurteilung/bezugsnormen.htm 17.04.22)

Die Leistung eines Lernenden kann man in erster Linie mit seiner Anfangsleistung vergleichen; die Bezugsgröße liegt also innerhalb der Person. Außerdem kann (und muss) sie auch zu außerhalb der Person liegenden Größen in Beziehung gesetzt werden. Das sind einerseits die Sache und die mit ihr gesetzten Lernziele (Kriterien), andererseits ggf. die Lernleistungen einer Gruppe von Lernenden.

Daraus ergeben sich drei Bezugsnormen: Individualnorm, Sachnorm (Idealnorm) und Sozialnorm.

Wer eine aktuelle Lernleistung richtig einschätzen will, muss wissen, wie schwer die gestellte Aufgabe war. Nur dann kann er z. B. feststellen, ob ein Lernender sich verbessert oder verschlechtert hat. Also muss er sie auch mit den entsprechenden Lernleistungen anderer Lernender vergleichen. Das allein genügt nicht, denn der Grad einer Lernleistung hängt zusätzlich von dem gesetzten Lernziel ab. Und hinter dieser Bezugsgröße steht noch die Frage des Standards, also des Niveaus, das unabhängig von bestimmten lernenden Personen vorgegeben ist und eingehalten werden soll.

Im Folgenden werden die einzelnen Bezugsnormen auf ihre Funktion, Aussagekraft und pädagogische Bedeutung näher untersucht.

Die Sozialnorm

In der Schulpraxis werden die Leistungen des einzelnen Schülers zunächst auf die Bezugsgruppe und deren Leistungsdurchschnitt bezogen. Das scheint auf den ersten Blick geradezu natürlich zu sein, weil die Leistung des einzelnen in die jeweilige Lerngruppe eingebettet ist und im Übrigen der Wunsch oder auch die Forderung nach „Gerechtigkeit" beachtet werden muss.

Vor allem anderen ist der Begriff Bezugsgruppe zu klären. Er bezeichnet alle Menschen einer Region, die durch vorgegebene Merkmale definiert sind, z.B. alle Schüler der siebenten Jahrgangsstufe der Gymnasien in Berlin oder gar in der ganzen Bundesrepublik. (...)

Die Sozialnorm als Grundlage für die Beurteilung schulischer Leistungen

Die Beurteilung von Schülerleistungen nach der Sozialnorm ist dann gegeben, wenn es darauf ankommt, Entscheidungen über Auslese, Platzierung u. Ä. korrekt zu treffen. Dazu müssen die Einzelleistungen mit denen in der gesamten Bezugsgruppe objektiv, gültig und zuverlässig verglichen werden.

Als Grundlage der Leistungsbeurteilung in der normalen Lerngruppe (Schulklasse, aber auch Jahrgang einer Schule) ist sie pädagogisch und psychologisch problematisch.

Vorzüge
Die Beurteilung vermeidet es, Leistungen nach einer starr linearen Verknüpfung zwischen Fehlerzahl und Note (z.B. in Diktaten) zu zensieren.

Die Beurteilung richtet sich nach der Leistungsfähigkeit der Lerngruppe.

Nachteile
Die Beurteilung bezieht sich lediglich auf die einzelne Lerngruppe und lässt keinen tragfähigen Vergleich mit den Leistungen anderer Lerngruppen zu.

Die Beurteilung lässt die vorgegebenen Standards unberücksichtigt und macht insbesondere keine Aussagen, wieweit die gesetzten Lernziele erreicht worden sind.

Die Beurteilung kann daher sowohl zu großzügig als auch zu streng sein. Anders gesagt: Es können Leistungen als gut bezeichnet werden, ohne es zu sein, und umgekehrt als schlecht gewertet werden, obwohl sie besser sind.

Der gewichtigste Einwand folgt jedoch aus der Tatsache, dass Lernfortschritte schwächerer Schüler deswegen nicht mit einer besseren Note gewürdigt werden können, weil bei wirksamem Unterricht die durchschnittliche Leistung der Lerngruppe gleichfalls steigt.

Die Sach-(Ideal-)norm

Diese Norm bezieht sich auf die Sache (...) (INGENKAMP 1985, S. 44). Weil sie reale Leistungen mit idealen Leistungen, der optimalen Erreichung von Lernzielen, vergleicht, heißt sie bei GAUDE (1989, S. 126) Idealnorm. Andere Autoren sprechen von kriterienbezogener Norm. Der Vergleich mit anderen Schülern interessiert hier kaum, entscheidend ist der Grad, in dem ein Lernziel erreicht worden ist. Diese Norm ist in § 5 der Notenbildungsverordnung abgebildet.

Vorzüge
Die Beurteilung informiert die am Lernprozess unmittelbar Beteiligten und Interessierten über die Ergebnisse des Lernens, also über die inzwischen erreichten Kompetenzen oder noch bestehenden Lücken des Lernenden.

Die Beurteilung eignet sich dazu, Lernfortschritte schwächerer, aber um Leistungsverbesserungen bemühter Schüler unverzüglich zu würdigen und dadurch deren Motivation zu stützen.

Die Beurteilung beruht auf klar und eindeutig beschriebenen Lernzielen. Das macht die Anforderungen für die Schüler und deren Eltern eindeutig und durchsichtig.

Nachteile
Der letztgenannte Vorzug bedingt auch einen Nachteil. Gerade die komplexeren und gleichzeitig pädagogisch relevanteren Lernziele lassen sich nur schwer oder gar nicht operationalisieren. Das kann dazu führen, dass sie gar nicht in den Lernzielhorizont aufgenommen werden.

Die Bestimmung der Lernziele ist eng mit dem Problem der Standards verknüpft. Für den einzelnen Lehrer ist es nicht einfach, zwischen zu hohen und zu niedrigen Anforderungen ein angemessenes Anforderungsniveau zu finden. Die Verführung ist beträchtlich, die Anforderungen zu niedrig anzusetzen.

Die Individualnorm

Diese Beurteilung erfasst den Lernzuwachs des Lernenden in einem bestimmten Zeitraum.

Vorzüge
Die Beurteilung entspricht ohne Zweifel am besten dem Wunsch, die Leistungen des einzelnen Schülers in der ihm angemessenen Weise zu würdigen und ihn auf diese Weise wirksam zu fördern. Leistungen werden optimal bekräftigt, Entmutigungen können aufgefangen werden.

Nachteile
Die Beurteilung führt wegen des individuellen Maßstabes zwangsläufig zu unterschiedlichen Maßstäben. Sie kann dadurch mit dem Gleichheitsgrundsatz in Konflikt geraten; er gebietet es, alle Leistungen nach demselben Maßstab zu bewerten.

Den dargestellten Vorzügen entspricht eine spezifische Schwäche. Die Bindung an einen vorgegebenen Standard, aber auch an konkrete Lernziele, kann aus falsch verstandener Rücksicht auf das Individuum leicht vernachlässigt werden.

5. Systematische Beurteilungsfehler

Beurteilungsfehler entstehen u.a. durch bewusste und unbewusste Verfälschungen seitens der Beurteiler. Sie sorgen dafür, dass Leistung und Beurteilung nicht übereinstimmen.

Überblick über ausgewählte Beurteilungsfehler:

(teilweise oder ganz unbewusste) Wahrnehmungsverzerrung	Maßstabsproblem	Bewusste Verfälschung	Kognitive Probleme
○ Halo-Effekt ○ Nikolaus-Effekt ○ Primacy-Effekt ○ Reaktionsbildung ○ Geschmack und Erwartungen des Beurteilenden ○ Sozialer Status/Beeinflussung durch Vor- bzw. Zusatzinformationen	○ Tendenz zur Mitte ○ Tendenz zur Strenge ○ Tendenz zur Milde ○ Sympathie-/Antipathie-Effekte ○ Reihenfolgeeffekte	○ Beurteilung als Mittel zum Zweck ○ Motivation ○ Disziplinierung	○ Erinnerungsprobleme ○ Beobachtungsprobleme

1. Wahrnehmungsverzerrungen stellen unbewusste Übertreibungen eines Beurteilers dar, die sich in verschiedene Richtungen entwickeln können:
   - Der *Halo-Effekt* (Überstrahlungseffekt) kommt dadurch zum Tragen, dass ein Beurteilungsmerkmal (z. B.: Wortgewandtheit) durch eine (unbewusste) Überbewertung durch den Beurteiler auf mehrere andere (z. B. Integrität, Sozialverhalten, Zuverlässigkeit) ausstrahlt, so dass der Beurteiler letztendlich nur ein Merkmal tatsächlich bewertet.
   - Der *Nikolaus-Effekt* drückt aus, dass der Beurteiler bei der Bewertung speziell auf Ereignisse, die erst kürzlich stattgefunden haben, eingeht.
   - Mit dem *Primacy-Effekt* (synonym: „First-Impression-Effekt“) wird ausgedrückt, dass die in einer Beurteilungsperiode bzw. -sequenz zuerst erhaltenen Informationen bzw. Eindrücke auf den Beurteiler größere Wirkung erzielen als später erhaltene und von daher unbewusst bei der Bewertung übergewichtet werden.
   - Mit *Reaktionsbildung* wird nach Freud ein Umschlagen ins Gegenteil bezeichnet. Das dient zur Wahrung eines positiven Selbstbilds. Wenn z. B. jemandem gesagt wird, ein Persönlichkeitstest habe ergeben, er sei geizig, dann kann es passieren, dass er sich danach ganz besonders großzügig verhält. Fürchtet eine Lehrperson, sie könne einen Schüler benachteiligen, dann kann es geschehen, dass sie ihn im Gegenteil bevorzugt, also ins Gegenteil umschlägt, nur um sich etwas Negatives („ich kann den nicht leiden, darum gebe ich ihm eine schlechte Note“) nicht eingestehen zu müssen. Das kann z. B. auch vermutet werden, wenn die Kinder einer beliebten Kollegin schlechter bewertet werden, als sie es verdient haben („ich will mir nicht nachsagen lassen müssen …“).
   - *Geschmack und Erwartungen des Beurteilenden:* Die Ansichten, Einstellungen und Erwartungen des Beurteilers beeinflussen das Verhalten der Versuchsperson und die Ergebnisse der Untersuchung. Urteile enthalten oft auch eine Aussage über den Beurteilenden („Ein langsamer Schüler, der weniger Fehler macht, ist mir lieber als einer, der schnell und unsorgfältig arbeitet.“).
   - *Sozialer Status / Beeinflussung durch Vor- bzw. Zusatzinformationen:* Je höher der soziale Status des Beurteilten ist bzw. je mehr positive Vorinformationen wir haben, desto besser beurteilen wir die beobachtete Leistung. Positive oder negative Meinungen von anderen hinterlassen eine Prägung, und ohne dass wir es merken, schließen

wir uns dieser Meinung an. Hier kommt oft ein „eigentlich-Denken“ zum Tragen („Die Tochter des Kollegen kann in der Arbeit zwar nicht korrekt chemisch rechnen, aber eigentlich ist sie sehr clever.“ – „Das Arbeiterkind hat zwar ein gutes Grundschulzeugnis, aber eigentlich ist das Gymnasium nichts für ihn (zumal schon ein Drittel der Klasse dorthin geht).“

2. *Maßstabsprobleme* beziehen sich auf unbewusste Verzerrungen der Beurteiler durch verschiedene Anspruchsniveaus bzw. Maßstäbe:
   - Bei der *Tendenz zur Mitte* geschieht eine unzutreffende Maßstabsanwendung dadurch, dass überproportional häufig mittlere Urteilswerte gewählt werden.
   - Bei der *Tendenz zur Milde* erfolgt eine unzutreffende Maßstabsanwendung, indem die Beurteiler in ihren Beurteilungen auf Skalen durchschnittlich nach oben abweichen. Ihr Anspruchsniveau ist faktisch niedriger.
   - Bei der *Tendenz zur Strenge* verwenden Beurteiler einen unzutreffenden Maßstab durch ein zu hohes Anspruchsniveau. Dies führt im Vergleich zu anderen Beurteilern zu überproportional niedrigen Einstufungen auf den Skalen.
   - Beim *Sympathiefehler* erfolgt eine verzerrte Maßstabsanwendung, indem auf die Beurteiler besonders sympathisch wirkende Schüler unbewusst besser bewertet werden als andere. Umgekehrtes Verhalten stellt einen Antipathie-Effekt dar.
   - *Reihenfolge-Effekte:* Sie können auftreten, wenn mehrere Beurteilungen nacheinander durchgeführt werden. Die erste Note setzt dann oft den Maßstab, mit dem die nachfolgenden Prüfungsleistungen verglichen werden. Es kann daher für die Note eines Schülers relevant sein, wer bereits vor ihm bewertet wurde. Es kommt auch vor, dass sich der Bewertungsmaßstab im Laufe einer Korrektur ändert, weil der Bewertende seinen ursprünglichen Erwartungshorizont durch die tatsächlich erbrachten Leistungen verändert.

3. Bei *bewussten Verfälschungen* (Wollensproblemen) schließlich erfolgen die Beurteilungen als Mittel zum Zweck, z. B. um Schüler zu disziplinieren, zu bestrafen, vermeintlich zu motivieren oder zu bevorzugen. Auch pädagogische Überlegungen können hierbei eine Rolle spielen (Bestehen der Probezeit).

4. Daneben bestehen noch verschiedene *kognitive Probleme* der Beurteilung (Kognitive Beurteilungspsychologie), die zu kaum beeinflussbaren Verzerrungen bei der Wahrnehmung, der Verarbeitung, der Speicherung, der Erinnerung und der Beobachtung von Informationen bzw. von Verhalten führen.

(vgl. http://www.wiwi.uni-bielefeld.de/~becker/lst/lehre/lexikonpm/503294966f0d00211.html, 15.04.08)

7. Ausblick auf die Prüfung

Die Referendarinnen und Referendare

- wenden die im Fach Schulrecht erworbenen Kenntnisse auf pädagogische Entscheidungen im Rahmen der Leistungsbeurteilung an (pädagogischer Beurteilungsspielraum, Gütekriterien, Bezugsnormorientierung u. a.) und berücksichtigen dabei insbesondere Aspekte der Inklusion.
- können Leistungserhebung, -messung und -beurteilung planen und durchführen und reflektieren (Beachtung der Gütekriterien, Transparenz des Erwartungshorizontes, Beurteilungsfehler, Beurteilungsanlässe (diagnostisch, formativ, summativ) u. a.), mündliche und schriftliche Notengebung.

Das erwarte ich in der Prüfung

- Siehe oben. Zur Erläuterung folgendes:
- Sie können die Gütekriterien für Leistungsmessung erläutern und auf vorgegebene Situationen anwenden.
- Sie können die Bezugsnormen-Problematik erläutern, diskutieren, an Ihrer eigenen Arbeit illustrieren und auf vorgegebene Situationen anwenden.
- Sie können die Beurteilungsanlässe erläutern, vorgegebene Situationen diesbezüglich analysieren und auf diesen Grundlagen auch Ideen für Diagnosen entwickeln. Dabei beziehen Sie sich auch auf die Inhalte der Veranstaltung „Pädagogische Diagnosen“.
- Sie können die dargestellten Beurteilungsfehler erläutern, in vorgegebenen Situationen identifizieren und Ideen entwickeln, wie solche Fehler vermieden werden können.